高级工程数学

2026-10-18

沈超敏

计算机科学与技术学院

cmshen@cs.ecnu.edu.cn

文附楼 105

今天内容

- **复习、拓展**

  Topic 2 Conditions

  Ch. 7 (**一维搜索方法**)

  Gradient Methods

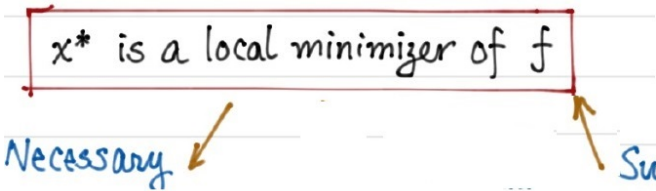
  Newton's Methods

- Lagrange **乘子法**
- The Karush–Kuhn–Tucker (KKT) Conditions

上次内容回顾: Topic 2: Optimality Conditions

Three acronyms:

- FONC (First Order Necessary Condition)
- SONC (Second Order Necessary Condition)
- SOSC (Second Order Sufficient Condition)



interior pt $\nabla f(\boldsymbol{x}^*) = 0, \nabla^2 f(\boldsymbol{x}^*) \geqslant 0$

general pt $\nabla f(\boldsymbol{x}^*) \cdot \boldsymbol{d} \geqslant 0 \quad \forall d$

If $\nabla f(\boldsymbol{x}^*) \cdot \boldsymbol{d} = 0$ for some $\boldsymbol{d}, \boldsymbol{d}^\top \nabla^2 f(\boldsymbol{x}^*)\, \boldsymbol{d} \geqslant 0$

$\nabla f(\boldsymbol{x}^*) = 0, \nabla^2 f(\boldsymbol{x}^*) > 0$

Topic 2: Conditions

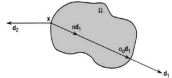
★ First Order Necessary Condition

Theorem. $\boldsymbol{x}^*$ is a local minimizer of f over Ω. Then for any feasible direction $\boldsymbol{d}$ at $\boldsymbol{x}^*$, we have

$$\nabla f\left(\boldsymbol{x}^*\right) \cdot \boldsymbol{d} \geqslant 0$$

Explanation. ① feasible direction $\boldsymbol{d}$ at a point $\boldsymbol{x} \in \Omega$ is a direction so that: starting from $\boldsymbol{x}$ and moving towards $\boldsymbol{d}$ remains in Ω.

Math language: $\exists \alpha_0 > 0$ s.t. $\boldsymbol{x} + \alpha \boldsymbol{d} \in \Omega, \forall \alpha \in [0, \alpha_0]$



② $\nabla f\left(\boldsymbol{x}^*\right) \cdot \boldsymbol{d}$: inner product of two vectors.

Also write as $\boldsymbol{d}^\top \nabla f\left(\boldsymbol{x}^*\right)$ or $\left(\nabla f\left(\boldsymbol{x}^*\right), \boldsymbol{d}\right)$, $\left\langle \nabla f(\boldsymbol{x}^*), \boldsymbol{d} \right\rangle$

$\frac{\partial f}{\partial \boldsymbol{d}} \triangleq \nabla f \cdot \boldsymbol{d}$ is the directional derivative when $\|\boldsymbol{d}\| = 1$

- ③ Define $\phi(\alpha) = f\left(\boldsymbol{x}^* + \alpha \boldsymbol{d}\right)$ for $\alpha \in [0, \alpha_0]$, then

$$\phi'(0) = \begin{cases} \lim_{\alpha \to 0^+} \frac{\phi(\alpha) - \phi(0)}{\alpha} = \lim_{\alpha \to 0^+} \frac{f(\boldsymbol{x}^* + \alpha \boldsymbol{d}) - f(\boldsymbol{x}^*)}{\alpha} & \text{Def} \\ \nabla f\left(\boldsymbol{x}^*\right) \cdot \boldsymbol{d} & \text{Chain rule} \end{cases}$$

Ch 7. One-Dimensional Search Methods

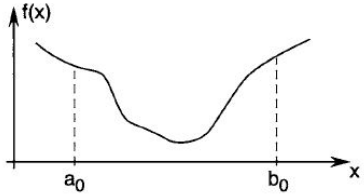


Figure 7.1 Unimodal function.

7.1 Introduction
7.2 Golden Section Search
7.3 Fibonacci Method
7.4 Bisection Method
7.5 Newton's Method
7.6 Secant Method
7.7 Bracketing
7.8 Line Search in Multidimensional Optimization

Topic 3: Gradient Methods

梯度方向是函数值增大最快的方向

Apply to $(\nabla f, \boldsymbol{d}) \leqslant \|\nabla f\| \cdot \|\boldsymbol{d}\| = \|\nabla f\|$ if $\|\boldsymbol{d}\| = 1$

Equality holds $\Leftrightarrow \boldsymbol{d} = \frac{\nabla f}{\|\nabla f\|}$

Therefore $-\nabla f(\boldsymbol{x})$ is the max-rate descending direction. When $\nabla f(\boldsymbol{x}) \neq \boldsymbol{0}$, for α sufficiently small, $f(\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x})) < f(\boldsymbol{x})$.

Topic 3: Gradient Methods

Gradient Descent Algorithm:

Start from $\boldsymbol{x}^0$ for $k = 0, 1, 2, \cdots$ till converge

$$\boldsymbol{x}^{k+1} = \boldsymbol{x}^k - \alpha_k \nabla f\left(\boldsymbol{x}^k\right)$$

Ideal condition: $\left\|\nabla f\left(\boldsymbol{x}^k\right)\right\| = 0$

Practical conditions:

gradient condition $\left\|\nabla f\left(\boldsymbol{x}^k\right)\right\| < \varepsilon$

success objective condition $\frac{\left|f\left(\boldsymbol{x}^{k+1}\right) - f\left(\boldsymbol{x}^k\right)\right|}{\left|f\left(\boldsymbol{x}^k\right)\right|} < \varepsilon$

successive point difference $\frac{\left\|\boldsymbol{x}^{k+1} - \boldsymbol{x}^k\right\|}{\left\|\boldsymbol{x}^k\right\|} < \varepsilon$

Replace denominator by $\max\left\{1, \left|f\left(\boldsymbol{x}^k\right)\right|\right\}$ or $\max\{1, \|\boldsymbol{x}^k\|\}$ to avoid division by tiny numbers.

梯度下降法的性质：相邻方向垂直

$$\alpha_k = \arg\min_{\alpha \geq 0} f(x_k - \alpha \nabla f(x_k)).$$

令

$$\phi(\alpha) = f(x_k - \alpha \nabla f(x_k)).$$

由于 α_k 是内部极小点，所以

$$\phi'(\alpha_k) = 0.$$

利用链式法则，

$$\phi'(\alpha) = -\nabla f(x_k - \alpha \nabla f(x_k))^T \nabla f(x_k).$$

代入 α_k，得到

$$-\nabla f(x_{k+1})^T \nabla f(x_k) = 0.$$

因此

$$\boxed{\nabla f(x_{k+1})^T \nabla f(x_k) = 0}$$

上次作业

编写一个完整的最速下降算法，

1. 定义 $f(\boldsymbol{x})$

2. 给出 $\boldsymbol{x}^*$ 的算法

运行时，输入 $f(\boldsymbol{x})$ 和 $\boldsymbol{x}_0$

输出 $\boldsymbol{x}^*$

Topic 4: Newton's method

Consider $\min_{x \in \mathbb{R}^n} f(x)$

- $n = 1$ $\quad x_{k+1} = x_k - \left(f''(x_k)\right)^{-1} f'(x_k)$
- $n > 1$ $\quad x_{k+1} = x_k - \left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k)$

Another form ① solve $\nabla^2 f(x_k)\, d_k = -\nabla f(x_k)$

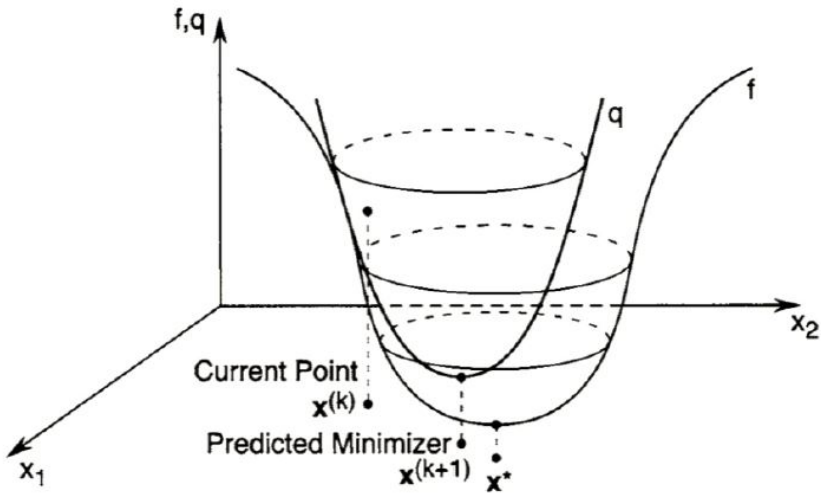
② update $x_{k+1} = x_k + d_k$

Remark. Do not require $\nabla^2 f(x_k) > 0$ only needs non-singular (invertible).

Namely, Newton's method also works for non-convex optimization problems.

but may not find local min.

Topic 4: Newton's method



今天：Lagrange 乘子法

A series of steps by which you could get the answer if you didn't understand what you were trying to do.

Feynman

即使你不明白自己在做什么，也能通过一系列步骤得到答案。

Video： Lagrange 乘子法 (Constrained Optimization)

1. Constrained optimization introduction

https://www.youtube.com/watch?v=vwUV2IDLP8Q

2. Lagrange multipliers, using tangency to solve constrained optimization

https://www.youtube.com/watch?v=yuqB-d5MjZA

3. Finishing the introduction to Lagrange multiplier example

https://www.youtube.com/watch?v=aep6lwPqm6I

4. Meaning of Lagrange multiplier

https://www.youtube.com/watch?v=m-G3K2GPmEQ

5. Proof for the meaning of Lagrange multipliers

https://www.youtube.com/watch?v=b9B2FZ5cqbM

约 30min

问题引入

很多极值问题, 目标函数的自变量不能在其定义域上自由变化, 而是要受到某些条件的约束.

例 (1)

要设计一个容积为 V 的长方形无盖水箱, 试问长、宽、高各等于多少时, 可使得表面积最小?

若设长、宽、高各等于 x, y, z, 则

目标函数: $S = 2z(x + y) + xy$;

约束条件: $xyz = V$.

定义 (极值（最值）)

设目标函数为

$$y = f(x_1, x_2, \cdots, x_n), \quad (x_1, x_2, \cdots, x_n) \in D \subset \mathbb{R}^n;$$

约束条件为如下一组方程:

$$\Phi : \varphi_k(x_1, x_2, \cdots, x_n) = 0, \quad k = 1, 2, \cdots, m \quad (m < n).$$

为简便起见, 记 $P = (x_1, x_2, \cdots, x_n)$, 并设

$$\Omega = \{P \mid P \in D, \varphi_k(P) = 0, k = 1, 2, \cdots, m\}.$$

若存在 $P_0 \in \Omega, \delta > 0$, 使得

$$f(P_0) \leq f(P), \quad \forall P \in \Omega \cap U(P_0; \delta) \text{ (或}\forall P \in \Omega),$$

则称 $f(P_0)$ 是 $f(P)$ 在约束条件 Φ 之下的极小值 (或最小值), 称 P_0 是相应的极小值点 (或最小值点).

类似地, 可定义条件极大 (或最大) 值.

拉格朗日乘数法

拉格朗日乘数法探源 先从 $n=2, m=1$ 的最简情形说起，即设目标函数与约束条件分别为

$$z=f(x, y) \quad \text{与} \quad \varphi(x, y)=0. \tag{1}$$

若由 $\varphi(x, y)=0$ 确定了隐函数 $y=y(x)$，则使得目标函数成为一元函数 $z=f(x, y(x))$. 再由

$$\frac{\mathrm{d}z}{\mathrm{d}x}=f_x+f_y \cdot \frac{\mathrm{d}y}{\mathrm{d}x}=f_x-f_y \cdot \frac{\varphi_x}{\varphi_y}=0$$

求出稳定点 $P_0\left(x_0, y_0\right)=\left(x_0, y\left(x_0\right)\right)$，在此点处满足

$$\left(f_x \varphi_y-f_y \varphi_x\right)\big|_{P_0}=0$$

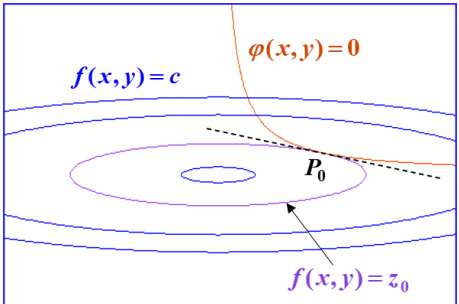
$$(f_x\varphi_y - f_y\varphi_x)|_{P_0} = 0, \quad \text{i.e.,} \quad \frac{f_x}{f_y} = \frac{\varphi_x}{\varphi_y}$$

而 f 的梯度为 (f_x, f_y), φ 的梯度为 (φ_x, φ_y), 所以 (f_x, f_y) 与 (φ_x, φ_y) 成比例。

或者说，表示 f 的等值线

$$f(x, y) = z_0$$

与曲线 $\varphi(x, y) = 0$ 在点 P_0 有公共切线, 见图.



由此推知: 存在比例常数 λ_0, 满足 $\left(f_x\left(P_0\right), f_y\left(P_0\right)\right)+\lambda_0\left(\varphi_x\left(P_0\right), \varphi_y\left(P_0\right)\right)=(0,0)$.

这又表示: 对于函数

$$L(x, y, \lambda)=f(x, y)+\lambda \varphi(x, y),$$

在点 $\left(x_0, y_0, \lambda_0\right)$ 处恰好满足:

$$\left(f_x \varphi_y-f_y \varphi_x\right)\big|_{P_0}=0$$

即

$$\begin{cases} L_x=f_x(x, y)+\lambda \varphi_x(x, y)=0, \\ L_y=f_y(x, y)+\lambda \varphi_y(x, y)=0, \\ L_\lambda=\varphi(x, y)=0. \end{cases} \tag{2}$$

也就是说, (2) 式是函数 $L(x, y, \lambda)$ 在其极值点处所满足的必要条件.

由此产生了一个重要思想:

拉格朗日乘数法 对于前面定义中所设的一般目标函数和约束条件组, 应引入辅助函数

$$
\begin{aligned}
&L\left(x_1, x_2, \cdots, x_n, \lambda_1, \lambda_2, \cdots, \lambda_m\right) \\
&= f\left(x_1, x_2, \cdots, x_n\right) + \sum_{k=1}^{m} \lambda_k \varphi_k\left(x_1, x_2, \cdots, x_n\right).
\end{aligned}
$$

称此函数为**拉格朗日函数**, 其中 $\lambda_1, \lambda_2, \cdots, \lambda_m$ 称为**拉格朗日乘数**.

拉格朗日乘数法应用举例

例 (1)

求 $S = 2(xz + yz) + xy$ 在约束条件 $V = xyz$ 下的极值.

解　此例 以往的解法是从条件式解出显函数, 例如 $z = \frac{V}{xy}$, 代入目标函数后, 转而求解

$$S = \frac{2V}{xy}(x + y) + xy$$

的普通极值问题.

无法将条件式作显化处理时, 此法就无法进行了.

现在作拉格朗日函数

$$L = 2(xz + yz) + xy + \lambda(xyz - V),$$

并求解以下方程组:

$$\begin{cases} L_x = 2z + y + \lambda yz = 0 \\ L_y = 2z + x + \lambda xz = 0 \\ L_z = 2(x + y) + \lambda xy = 0, \\ L_\lambda = xyz - V = 0. \end{cases}$$

为消去 λ, 将前三式分别乘以 x, y, z, 则得

$$\begin{cases} 2xz + xy = -\lambda xyz \\ 2yz + xy = -\lambda xyz \\ 2z(x + y) = -\lambda xyz \end{cases}$$

两两相减后立即得出 $x = y = 2z$, 再代入第四式, 得

$$x = \sqrt[3]{2V} = y, z = \sqrt[3]{2V}/2.$$

注 由以上结果还可以得到一个不等式 (这是获得不等式的一种好方法). 那就是具体算出目标函数 (表面积) 的最小值:

$$S_{\min} = 2 \cdot \frac{\sqrt[3]{2V}}{2}(\sqrt[3]{2V} + \sqrt[3]{2V}) + (\sqrt[3]{2V})^2 = 3\sqrt[3]{4V^2}$$

于是有 $2z(x+y) + xy \geq 3\sqrt[3]{4V^2}$, 其中 $V = xyz$. 消去 V 后便得不等式

$$2z(x+y) + xy \geq 3\sqrt[3]{4(xyz)^2}, \quad x > 0, y > 0, z > 0$$

例 (2)

抛物面 $z = x^2 + y^2$ 被平面 $x + y + z = 1$ 截成一个椭圆. 求该椭圆到原点的最长和最短距离.

解 这个问题的目标函数是 $f(x, y, z) = \sqrt{x^2 + y^2 + z^2}$ 在条件 $z = x^2 + y^2$ 及 $x + y + z = 1$ 下的最值问题.

为了计算方便, 把目标函数改取距离的平方 (这是等价的), 即设

$$L = x^2 + y^2 + z^2 + \lambda \left(x^2 + y^2 - z \right) + \mu(x + y + z - 1).$$

求解以下方程组:

$$\left.\begin{aligned} L_x &= 2x + 2\lambda x + \mu = 0, \\ L_y &= 2y + 2\lambda y + \mu = 0, \\ L_z &= 2z - \lambda + \mu = 0, \\ L_\lambda &= x^2 + y^2 - z = 0, \\ L_\mu &= x + y + z - 1 = 0. \end{aligned}\right\} \Rightarrow \left\{\begin{aligned} & 2(x + \lambda x) \\ &= 2(y + \lambda y) \\ &= 2z - \lambda. \end{aligned}\right.$$

由此又得 $(1+\lambda)(x-y) = 0 \Rightarrow x = y$. **再代入条件式, 继而得到: (这里** $\lambda \neq -1$, **否则将无解)**

$$2x^2 + 2x - 1 = 0$$

$$x = y = \frac{-1 \pm \sqrt{3}}{2}, z = 1 - (-1 \pm \sqrt{3}) = 2 \mp \sqrt{3}$$

这是拉格朗日函数的稳定点. 由于所求问题存在最大值和最小值, 所以

$$x^2+y^2+z^2=\frac{2(-1\pm\sqrt{3})^2}{4}+(2\mp\sqrt{3})^2$$
$$=\begin{cases}\frac{1}{2}(1-2\sqrt{3}+3)+4-4\sqrt{3}+3=9-5\sqrt{3},\\ \frac{1}{2}(1+2\sqrt{3}+3)+4+4\sqrt{3}+3=9+5\sqrt{3}.\end{cases}$$

故原点至已知曲线上点的最小距离与最大距离分别为

$$d_{\min}=\sqrt{9-5\sqrt{3}},\quad d_{\max}=\sqrt{9+5\sqrt{3}}$$

例 (3)

已知圆柱面

$$x^2 + y^2 + z^2 - xy - yz - zx - 1 = 0, \tag{4}$$

它与平面 $x + y - z = 0$ 相交得一椭圆, 试求此椭圆的面积.

分析

(i) 如果能求得该椭圆的长、短半轴 a 与 b, 则椭圆面积为 πab;

(ii) 由方程 (4) , 此圆柱面关于坐标原点是对称的, 故此圆柱面的中心轴是通过坐标原点的某一直线;

(iii) 因为所给平面也是通过坐标原点的, 所以此平面上的椭圆截线必以坐标原点为其中心点.

解 由以上分析, 自原点至椭圆上任意点 (x, y, z) 的距离 $d = \sqrt{x^2 + y^2 + z^2}$ 之最大、小值, 就是该椭圆的长、短半轴.

(说明: 本例的题型与例 2 相类似, 但在具体计算策略上将有较大差异.)

设拉格朗日函数为

$$\begin{aligned} L = x^2 + y^2 + z^2 + \lambda(x + y - z) \\ - \mu\left(x^2 + y^2 + z^2 - xy - yz - zx - 1\right) \end{aligned}$$

并令

$$
\begin{cases}
L_x = 2x + \lambda - \mu(2x - y - z) = 0, & (5)\\
L_y = 2y + \lambda - \mu(2y - z - x) = 0, & (6)\\
L_z = 2z - \lambda - \mu(2z - x - y) = 0, & (7)\\
L_\lambda = x + y - z = 0, & (8)\\
L_\mu = -(x^2 + y^2 + z^2 - xy - yz - zx - 1) = 0. & (9)
\end{cases}
$$

对 (5), (6), (7) 三式分别乘以 x, y, z 后相加, 得到

$$
\begin{aligned}
&2\left(x^2 + y^2 + z^2\right) + \lambda(x + y - z)\\
&- 2\mu\left(x^2 + y^2 + z^2 - xy - yz - zx\right) = 0,
\end{aligned}
$$

借助 $(8),(9)$ 两式进行化简, 又得

$$d^2 = x^2 + y^2 + z^2 = \mu.$$

这说明 d^2 的极值就是这里的 μ (即 d 的极值就是 $\sqrt{\mu}$). 问题便转而去计算 μ.

为此先从 (5) $-(8)$ 式消去 λ, 得到一个线性方程组:

$$\begin{cases} (2-\mu)x + 2\mu y + (2-\mu)z = 0 \\ 2\mu x + (2-\mu)y + (2-\mu)z = 0 \\ x + y - z = 0 \end{cases}$$

它有非零解 (x, y, z) 的充要条件是

$$\begin{vmatrix} 2-\mu & 2\mu & 2-\mu \\ 2\mu & 2-\mu & 2-\mu \\ 1 & 1 & -1 \end{vmatrix} = -3\mu^2 + 20\mu - 12 = 0$$

即

$$\mu^2 - \frac{20}{3}\mu + 4 = 0. \tag{10}$$

由前面讨论知道, 方程 (10) 的两个根 μ_1, μ_2 就是 d^2 的最大、小值, 即 a^2 与 b^2; 而 $\mu_1\mu_2 = 4$, 于是

$$S = \pi ab = \pi\sqrt{\mu_1\mu_2} = 2\pi. \tag{0.1}$$

说明

(i) 一旦由方程 (5) -(9) 能直接求得椭圆的长、短半轴, 那就不必再去计算椭圆的顶点坐标 (x, y, z) 了, 这使解题过程简单了许多.

(ii) 若用解析几何方法来处理本例的问题, 则需要先求出圆柱面的中心轴所在直线 $l: x = y = z$, 再求出纬圆半径 $r = \sqrt{\frac{2}{3}}$ 和纬圆面积 $A = \frac{2\pi}{3}$; 还有平面 $x + y - z = 0$ 的法线与 l 夹角的余弦

$$\cos\theta = \frac{(1,1,1)\cdot(1,1,-1)}{\sqrt{3}\cdot\sqrt{3}} = \frac{1}{3}.$$

然后根据面积投影关系 $A = S\cos\theta$, 最后求得椭圆面积为 $S = \frac{A}{\cos\theta} = \frac{2\pi}{3}/\frac{1}{3} = 2\pi$.

例 (4)

设光滑封闭曲线

$$\Gamma : F(x, y) = 0.$$

证明: Γ 上任意两个相距最远点处的切线互相平行, 且垂直于这两点间的连线.

证 由于 Γ 是光滑封闭曲线, 所以满足:

(i) $\boldsymbol{F}$ 在一个包含 Γ 的开域内有连续的一阶偏导数, 且 $F_x{}^2 + F_y^2 \neq 0$;

(ii) 在 Γ 上必有相距最远的点.

设 $P_0\left(x_0, y_0\right), Q_0\left(u_0, v_0\right)$ 为 Γ 上相距最远的两点. 题目转化为:

求目标函数

$$f(x, y, u, v)=(x-u)^2+(y-v)^2$$

在约束条件

$$F(x, y)=0, F(u, v)=0$$

之下的极大值 $f\left(x_0, y_0, u_0, v_0\right)$.

于是由拉格朗日乘数法, 存在 λ_0, μ_0, 使点 M_0 成为拉格朗日函数

$$L=(x-u)^2+(y-v)^2+\lambda F(x, y)+\mu F(u, v)$$

的稳定点. 从而满足

$$\begin{cases} 2\left(x_0-u_0\right)+\lambda_0 F_x\left(x_0,y_0\right)=0 \\ 2\left(y_0-v_0\right)+\lambda_0 F_y\left(x_0,y_0\right)=0 \\ -2\left(x_0-u_0\right)+\mu_0 F_u\left(u_0,v_0\right)=0 \\ -2\left(y_0-v_0\right)+\mu_0 F_v\left(u_0,v_0\right)=0 \end{cases}$$

由前两式与后两式分别得到

$$\left(x_0-u_0,y_0-v_0\right) /\!/ \left(F_x,F_y\right)\big|_{P_0},$$
$$\left(x_0-u_0,y_0-v_0\right) /\!/ \left(F_u,F_v\right)\big|_{Q_0}$$

前者表示 $\overline{P_0Q_0}$ 与 Γ 在 P_0 的切线垂直, 后者表示 $\overline{P_0Q_0}$ 与 Γ 在 Q_0 的切线垂直.

所以 Γ 在 P_0, Q_0 两点处的切线互相平行, 且垂直于 $\overline{P_0Q_0}$.

今天：含有不等式的 Constrained Optimization

The Karush–Kuhn–Tucker (KKT) Conditions

`https://www.youtube.com/watch?v=uh1Dk68cfWs&t=606s` （2'30" 开始）

- 引入 $\max_{u \geq 0} ux$
- Dual
- KKT

性质：Primal $\geq$ Dual

原问题：$\min_{x} \max_{\lambda,\nu} L(x,\lambda,\nu)$

$s.t.\ \ \lambda \geq 0$

对偶问题：$\max_{\lambda,\nu} g(\lambda,\nu) = \max_{\lambda,\nu} \min_{x} L(x,\lambda,\nu)$

$s.t.\ \ \lambda \geq 0$

$$L(x,\lambda,\nu) = f_0(x) + \sum \lambda_i f_i(x) + \sum \nu_i h_i(x)$$

$$\max_{\lambda,\nu} L(x,\lambda,\nu) \geq L(x,\lambda,\nu) \geq \min_{x} L(x,\lambda,\nu)$$

$$A(x) = \max_{\lambda,\nu} L(x,\lambda,\nu) \geq L(x,\lambda,\nu) \geq \min_{x} L(x,\lambda,\nu) = I(\lambda,\nu)$$

$$A(x) \geq I(\lambda,\nu) \quad \text{——恒成立}$$

$$A(x) \geq \min_{x} A(x) \geq \max_{\lambda,\nu} I(\lambda,\nu) \geq I(\lambda,\nu)$$

$$P^* = \min_{x} A(x) \geq \max_{\lambda,\nu} I(\lambda,\nu) = D^*$$

KKT Conditions

Given general problem

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{subject to} \quad & h_i(x) \leq 0, \quad i = 1, \dots m \\ & \ell_j(x) = 0, \quad j = 1, \dots r \end{aligned}$$

The **Karush-Kuhn-Tucker conditions** or **KKT conditions** are:

- $0 \in \partial f(x) + \sum_{i=1}^{m} u_i \partial h_i(x) + \sum_{j=1}^{r} v_j \partial \ell_j(x)$ (stationarity)
- $u_i \cdot h_i(x) = 0$ for all i (complementary slackness)
- $h_i(x) \leq 0,\ \ell_j(x) = 0$ for all i, j (primal feasibility)
- $u_i \geq 0$ for all i (dual feasibility)

例子 1

$$\{\min_x x^2 \mid 1 \le x \le 2\}$$

解：化成标准形式

$$\{\min_x x^2 \mid -x + 1 \le 0 \text{ and } x - 2 \le 0\}$$

求解

$$\min_x \quad x^2 + \max_{\lambda_1 \ge 0, \lambda_2 \ge 0} \lambda_1(-x+1) + \lambda_2(x-2)$$

i.e.,

$$\min_x \max_{\lambda_1 \ge 0, \lambda_2 \ge 0} x^2 + \lambda_1(-x+1) + \lambda_2(x-2)$$

交换，得

$$\max_{\lambda_1 \ge 0, \lambda_2 \ge 0} \min_x \quad x^2 + \lambda_1(-x+1) + \lambda_2(x-2)$$

KKT Conditions

由 KKT, 则

1. $\nabla_x L = 0$, 即 $2x - \lambda_1 + \lambda_2 = 0 \Rightarrow x^* = \frac{\lambda_1 - \lambda_2}{2}$
2. $\lambda_1(-x+1) = 0$, 且 $\lambda_2(x-2) = 0$
3. $\lambda_1 \geq 0$, $\lambda_2 \geq 0$
4. $-x + 1 \leq 0$, $x - 2 \leq 0$

#2 为

$$\begin{cases} \lambda_1 = 0 \\ \lambda_2 = 0 \end{cases} \text{ 或 } \begin{cases} x = 1 \\ x = 2 \end{cases} \Rightarrow \begin{cases} \lambda_1 = 0 \text{ or } x = 1 \\ \lambda_2 = 0 \text{ or } x = 2 \end{cases}$$

因此, 由

$$\begin{cases} x = 1 \\ \lambda_2 = 0 \end{cases} \Rightarrow x^* = 1.$$

例子 2

$$\begin{aligned} \min\ & f(x_1, x_2) = x_1^2 + 2x_2^2 - 4x_1 - 4x_2 \\ \text{s.t.}\quad & g_1(x_1, x_2) = x_1 + x_2 - 3 \le 0 \\ & g_2(x_1, x_2) = 5 - x_1 - 2x_2 \le 0 \end{aligned}$$

解：拉格朗日函数为：

$$L(x_1, x_2, \lambda_1, \lambda_2) = x_1^2 + 2x_2^2 - 4x_1 - 4x_2 + \lambda_1(x_1 + x_2 - 3) + \lambda_2(5 - x_1 - 2x_2)$$

对 x_1 和 x_2 求偏导得到的等式为：

$$\frac{\partial L}{\partial x_1} = 2x_1 - 4 + \lambda_1 - \lambda_2 = 0 \tag{0.2}$$

$$\frac{\partial L}{\partial x_2} = 4x_2 - 4 + \lambda_1 - 2\lambda_2 = 0 \tag{0.3}$$

例子 2（续 1）

$$\text{i.e., } \nabla f + \lambda_1 \nabla g_1 + \lambda_2 \nabla g_2 = \begin{pmatrix} 2x_1 - 4 \\ 4x_2 - 4 \end{pmatrix} + \lambda_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda_2 \begin{pmatrix} -1 \\ -2 \end{pmatrix} = 0$$

另外，$\lambda_i g_i = 0$ $(i = 1, 2)$. 所以，4 个未知数，4 个方程，

注：$\lambda_i g_i = 0$ + KKT 条件中的不等式，具体含义为：

1. 若 $\lambda_1 = \lambda_2 = 0$，则 $g_1 < 0$, $g_2 < 0$;
2. 若 $\lambda_1 = 0$, $\lambda_2 > 0$，则 $g_1 < 0$, $g_2 = 0$;
3. 若 $\lambda_1 > 0$, $\lambda_2 = 0$，则 $g_1 = 0$, $g_2 < 0$;
4. 若 $\lambda_1 > 0$, $\lambda_2 > 0$，则 $g_1 = 0$, $g_2 = 0$.

例子 2（续 2）

无论哪种情形，主要是求解上面写的求导后的梯度方程，即：

$$\frac{\partial L}{\partial x_1} = 2x_1 - 4 + \lambda_1 - \lambda_2 = 0,$$

$$\frac{\partial L}{\partial x_2} = 4x_2 - 4 + \lambda_1 - 2\lambda_2 = 0.$$

(i) 若 $\lambda_1 = \lambda_2 = 0$，则 $g_1 < 0,\ g_2 < 0$

若 $\lambda_1 = \lambda_2 = 0$，则只需要求解 $x_1,\ x_2$ 即可：

$$\frac{\partial L}{\partial x_1} = 2x_1 - 4 = 0 \Rightarrow x_1 = 2$$

$$\frac{\partial L}{\partial x_2} = 4x_2 - 4 = 0 \Rightarrow x_2 = 1$$

例子 2（续 3）

那么 $x_1 = 2, x_2 = 1$ 就是其中的一个解了吗？

还得验证下该解是否满足不等式 $g_1 < 0$ 和 $g_2 < 0$。

将 $x_1 = 2, x_2 = 1$ 带入 g_1 和 g_2，有：

$$g_1(x_1, x_2) = x_1 + x_2 - 3 = 2 + 1 - 3 = 0$$

$$g_2(x_1, x_2) = 5 - x_1 - 2x_2 = 5 - 2 - 2 = 1 > 0$$

很遗憾，两个式子都无法使得 $g_1 < 0$ 和 $g_2 < 0$，故只能舍弃该解。

例子 2（续 4）

(ii)、(iii) 类似，我们以（iii）为例

（iii）的情形为：$\lambda_1 > 0, \lambda_2 = 0$，则 $g_1 = 0, g_2 < 0$

$$\begin{cases} \frac{\partial L}{\partial x_1} = 2x_1 - 4 + \lambda_1 - \lambda_2 = 0 \\ \frac{\partial L}{\partial x_2} = 4x_2 - 4 + \lambda_1 - 2\lambda_2 = 0 \\ g_1(x_1, x_2) = x_1 + x_2 - 3 = 0 \\ \lambda_2 = 0 \end{cases} \Rightarrow \begin{cases} x_1 = 2 \\ x_2 = 1 \\ \lambda_1 = 0 \\ \lambda_2 = 0 \end{cases}$$

发现此解与情形 1 的解一样（仅是这个例子一样，一般不会一样），但带入 g_2 函数时，有：

$$g_2(x_1, x_2) = 5 - x_1 - 2x_2 = 5 - 2 - 2 = 1 > 0$$

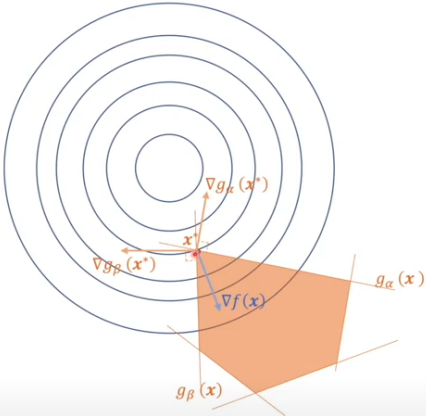
很可惜，依然不能使得 $g_2 < 0$，故该解还是需要舍弃。

例子 2（续 5）

(iv) 若 $\lambda_1 > 0, \lambda_2 > 0$，则 $g_1 = 0, g_2 = 0$

此时，最优解在 g_1 和 g_2 函数的边界上，联立的四个方程为：

$$\begin{cases} \frac{\partial L}{\partial x_1} = 2x_1 - 4 + \lambda_1 - \lambda_2 = 0 \\ \frac{\partial L}{\partial x_2} = 4x_2 - 4 + \lambda_1 - 2\lambda_2 = 0 \\ g_1(x_1, x_2) = x_1 + x_2 - 3 = 0 \\ g_2(x_1, x_2) = 5 - x_1 - 2x_2 = 0 \end{cases} \Rightarrow \begin{cases} x_1 = 1 \\ x_2 = 2 \\ \lambda_1 = 8 \\ \lambda_2 = 6 \end{cases}$$



$\min f(\boldsymbol{x}), \boldsymbol{x} \in \mathbb{R}^n$

$s.t.\ \ g_i(\boldsymbol{x}) = \boldsymbol{a_i^T} \cdot \boldsymbol{x} + b_i \leq 0$ 其中i = 1,2,3 ... m, $\boldsymbol{a_i} \in \mathbb{R}^n, b_i \in \mathbb{R}$

$$L(\boldsymbol{x}, \boldsymbol{\lambda}) = f(\boldsymbol{x}) + \sum \lambda_i g_i(\boldsymbol{x})$$

$$\Downarrow$$

$$\nabla L(\boldsymbol{x}, \boldsymbol{\lambda}) = 0$$

$$\Downarrow$$

$$-\nabla f(\boldsymbol{x}) = \sum \lambda_i \cdot \nabla g_i(\boldsymbol{x})$$

KKT Conditions 的局限性

1. 必要，非充分

2. 方程可能不容易求解

KKT 的程序（ChatGPT 生成）

```python
import sympy as sp

def kkt_solver_symbolic(objective_func, variables, constraints):
    """
    使用 KKT 条件求解非线性优化问题，通过符号求解方程。

    参数:
    - objective_func: 目标函数，用户定义的符号表达式。
    - variables: 决策变量的符号列表。
    - constraints: 一个包含等式和不等式约束的字典:
        - 'eq': 等式约束的列表，每个约束是一个符号表达式。
        - 'ineq': 不等式约束的列表，每个约束是一个符号表达式。

    返回:
    - 解的结果，包括最优解和拉格朗日乘子。
    """

    # 计算目标函数的梯度
    objective_grad = [sp.diff(objective_func, var) for var in variables]

    # 创建拉格朗日乘子
    lambdas = sp.symbols(f'lambda:{len(constraints["eq"])}')
    mus = sp.symbols(f'mu:{len(constraints["ineq"])}')

    # 梯度条件方程
```

```python
# 测试使用
if __name__ == "__main__":
    # 定义符号变量
    x1, x2 = sp.symbols('x1 x2')

    # 目标函数 f(x) = 0.5 * x1^2 + 0.5 * x2^2
    objective_func = 0.5 * x1**2 + 0.5 * x2**2

    # 等式约束 x1 + x2 - 1 = 0
    eq_constraint = x1 + x2 - 1

    # 不等式约束 x1 >= 0, x2 >= 0
    ineq_constraint1 = x1
    ineq_constraint2 = x2

    constraints = {
        'eq': [eq_constraint],
        'ineq': [ineq_constraint1, ineq_constraint2]
    }

    # 调用 KKT 求解器
```

KKT 的程序（更一般的解法）

1. 定义拉格朗日函数

构造拉格朗日函数：

$$L(x, \lambda, \mu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \mu_j h_j(x)$$

其中，λ 是等式约束的拉格朗日乘子，μ 是不等式约束的拉格朗日乘子，且 $\mu_j \geq 0$。

2. 初始化

选择一个初始猜测值 x_0，并初始化拉格朗日乘子 λ 和 μ（通常设置为零或较小的正数）。

3. 迭代步骤

1. **梯度步**：在每一步，更新 x 使得它沿着负梯度的方向前进，尽量减少拉格朗日函数值：

   $$x_{k+1} = x_k - \alpha \nabla_x L(x_k, \lambda_k, \mu_k)$$

   其中 α 是步长，通常可以通过线搜索确定。

2. **拉格朗日乘子更新**：
   - 对于等式约束，更新拉格朗日乘子 λ：

     $$\lambda_{k+1} = \lambda_k + \beta g(x_{k+1})$$

   - 对于不等式约束，更新拉格朗日乘子 μ：

     $$\mu_{j,k+1} = \max(0, \mu_{j,k} + \beta h_j(x_{k+1}))$$

     这里 β 是拉格朗日乘子的步长。

3. **检查 KKT 条件的收敛性**：
   - 检查以下条件是否满足：
     - 梯度条件：$\nabla_x L(x, \lambda, \mu) \approx 0$
     - 可行性条件：约束 $g_i(x) = 0$ 和 $h_j(x) \leq 0$
     - 互补松弛条件：$\mu_j h_j(x) = 0$
   - 如果满足这些条件，则停止迭代；否↓ 继续迭代。

作业: 利用 KKT conditions 求解 Optimization 问题

$$\min_x x^3 + 2x^2 - x + 1$$

$$\text{s.t. } x^2 \leq 1$$